实验 1　线性回归（最小二乘）

课程名称：机器学习　**课程代码：**210901045

实验类型：综合　　**总学时** 32（理论 26、实验 6）　**本实验** 2 学时

一、实验目的

1. 完成“加载→划分→训练集拟合预处理→训练→预测→评估→画图”的完整机器学习流程，能够独立开展模型的训练与评估。

2. 掌握 train/test、shape、fit/predict 与 scaler 的含义和使用方法；记录并解释训练/测试 MSE、RMSE、R^2 等相关指标。

3. 在教师指导下完成 BMI 一元公式计算及 NumPy 多元 fit/predict 类实现，核对与 sklearn 的结果；并在报告写出一元与多元最小二乘推导过程（包含公式的成立条件）。

二、实验要求

工具：课程指定 Python 环境与 NumPy、scikit-learn、Matplotlib、Jupyter；pandas 非必需，CPU 即可。运行导入单元，无报错再继续；缺包先核对环境与内核，不随意切换安装。

材料：打开“实验 1_线性回归.ipynb”，按任务编号跟做。完整类框架与绘图代码在 Notebook 中，不要求从空白文件独立写类。教师分块演示，学生运行自己的文件、保留真实输出。

任务：任务 1—5 必做，任务 6—8 无代码填空，只要求“运行并理解”。课后提交两个文件：完成的 notebook（ipynb）与实验报告（doc/docx），要求统一用“学号+姓名_实验 1”命名。

三、实验内容

Python 基础知识与 notebook 基本操作

Notebook：单击代码单元，Shift+Enter 运行；[*]表示正在执行，不能连续重复点击。按从上到下的顺序运行；修改前面的单元后，重跑后面相关单元。Ctrl+S 保存；提交前重启内核并运行全部单元。

Python：X 是二维特征矩阵，每行一个样本、每列一个特征；y 是一维连续目标。shape 返回尺寸；X[:, 2]取 BMI 一维列，X[:, 2:3]保留二维列，供 sklearn 拟合。Python 从 0 计数，BMI 为第 3 列。Notebook 前置基础 F3 设有 1 处切片小练习：把取出的列保留成二维（如 demo_X[:, 0:1]），正是任务 4a 取 BMI 列 Xtr[:, 2:3]的写法。

机器学习：fit 用训练数据求参数；predict 用已训练模型生成预测。scaler 是预处理器：fit_transform 在训练集求均值/标准差并转换，transform 沿用这些参数；测试集不参与 fit，y 不标准化。

任务 1【必做】数据准备

操作说明：加载 load_diabetes，检查尺寸、特征与非有限/缺失值；固定划分，训练集拟合 scaler。内置数据无需联网下载，442 个样本、10 个特征，目标为一年后病情进展的定量指标，仅用于教学，不作医学诊断。

预期输出：X 为(442, 10)，y 为(442,)；非有限值检查均为 True，无缺失；训练(309, 10)、测试(133, 10)。能指出 scaler 只在 Xtr 上 fit。

其他说明：load_diabetes 默认特征已按全数据预中心化并按“标准差×√样本数”缩放，不是原始 BMI kg/m²。再做训练集 StandardScaler 是示范规范流程，并非 OLS 必须标准化；内置预缩放是教学数据限制，不能宣称原始数据完全无泄漏。任务 4a 保留默认 BMI 尺度，不再次标准化。

任务 2【必做】sklearn 训练与预测

操作说明：用全部 10 个标准化特征拟合 LinearRegression，分别预测训练集和测试集；保留系数与截距。

预期输出：系数 shape 为(10,)，测试预测 shape 为(133,)；fit 使用 Xtr_s、ytr，predict 不传真实 y。

任务 3【必做】MSE、RMSE、R^2

操作说明：记录训练/测试各三项指标，共六项，并解释含义。$MSE=\Sigma(y-\hat{y})^2/n$，$RMSE=\sqrt{MSE}$；$R^2=1-\Sigma(y-\hat{y})^2/\Sigma(y-\bar{y})^2$，其中$\bar{y}$为当前评估集合真实目标均值。

预期输出：得到两行有限数字；$RMSE^2$与 MSE 一致。MSE 单位是目标单位平方，RMSE 与目标同量纲；二者通常越小越好。R^2为 1 表示完美、0 表示与本集合均值基线相当，可为负。

探索任务：任务 3 之后 Notebook 设有“探索沙盒”，只改本单元的 test_size 或 random_state，用同一流程重训并对比训练/测试指标，体会划分对泛化的影响。

任务 4a【必做】BMI 一元公式计算与对照

操作说明：用训练 BMI 和 ytr 计算斜率、截距，再与同一训练 BMI 的一元 sklearn 模型对照。BMI 用 `ibmi = list(d.feature_names).index('bmi')`，不再标准化，也不使用多元模型的 BMI 系数。

预期输出：得到 w0_manual、w1_manual 及 allclose=True；报告列两种斜率、截距、差值和容差，True 只表示容差内一致。

任务 4b【必做】多元推导、NumPy 类与对照

操作说明：在给定 NumpyLinearRegression 类框架中按指导补齐 fit/predict：添加全 1 列，用 lstsq 求参数、保存截距及系数，再用同尺度的测试特征预测。不能用 BMI 单列替代 10 特征实现。

预期输出：增广矩阵为(309, 11)，rank 为 11；系数、截距、133 个预测的三个 allclose 均有真实输出，记录最大预测绝对差。

任务 5【必做】输出两幅结果图

操作说明：图 1 画 10 特征模型测试真实值（横轴）与预测值（纵轴）的散点及 y=x 参考线；图 2 画训练集默认预缩放 BMI 与目标的散点及 4a 的一元拟合线。

预期输出：两幅图显示并保存；标题、横纵轴与尺度清楚。说明图 1 偏离 y=x 表示预测误差，图 2 离散表示 BMI 单特征不能解释全部目标变化。

特别提醒：图 2BMI 不是原始医学单位；不能把多元模型 BMI 系数当成图 2 斜率。当前图中均用英文标签避免中文字体缺失问题，可尝试配置中文字体（选做），在报告图注中用中文解释，图片中必须包含本人学号（位置不限）。

（任务 6—8 运行并理解即可）

任务 6：Ridge 四档对照

操作说明：比较 OLS（alpha=0，用 LinearRegression）与 Ridge（alpha=0.1、1、10）。

预期输出：四档各有训练/测试 MSE、RMSE、R^2共六项指标及系数 L2 范数（不含截距）；讨论正则化，不预设测试结果一定改善。

任务 7：多项式复杂度对照

操作说明：固定 degree=1、2、3，比较训练与测试的六项指标。用同一原始划分 Xtr/Xte 建立 PolynomialFeatures(include_bias=False)→StandardScaler→LinearRegression；先扩展再标准化。整个 Pipeline 只在 Xtr、ytr 上 fit，测试只 predict。

预期输出：三组指标和扩展后维数；结合泛化差距讨论复杂度，不预设必然过拟合。

任务 8：十特征线性梯度下降

操作说明：沿用 Xtr_s 的 10 个特征，A=[1, Xtr_s]，用 MSE=SSE/n=$\|A\theta-ytr\|^2/n$ 迭代求线性参数。Notebook 选做 8 中，$g=2A^T(A\theta-ytr)/n$，$H=2A^TA/n$，$L=\lambda max(H)$，$\eta=1/L$；初始化 b=mean(ytr)、w=0，按$\theta\leftarrow\theta-\eta g$ 迭代。

预期输出：保留“迭代次数—训练 MSE”曲线、步长与次数及 lstsq 测试预测差；说明十特征而非 BMI 分支，有限迭代的近似误差不是求解器逐位相等。

四、实验报告与提交要求

每人提交一份 Word 报告（doc/docx）及 notebook（ipynb）代码。命名为“学号+姓名_实验 1”，例如“2022010101 张三_实验 1.docx”和“2022010101 张三_实验 1.ipynb”。由各班班长统一收齐，一周之内提交。

报告需使用实验报告模板，须依次包含以下内容：

①基本信息与目的。姓名、学号、实际班级、实验日期，用自己的话说明实验目的；

②数据与方法。数据来源、形状、特征及非有限/缺失检查，固定划分参数（test_size=0.3、random_state=42）与训练/测试尺寸，训练集 scaler 拟合范围及 BMI 默认预缩放尺度说明；

③4a 与 4b 理论推导。写出推导过程，不能只写结论。公式可用 Word 公式编辑器或清晰手写照片。至少包含：（4a）一元模型和损失函数、两个偏导方程、整理后的斜率/截距公式及其成立条件；（4b）多元最小二乘的增广矩阵及其损失函数、梯度、正规方程及解（包含成立条件）；

④关键代码与对照。贴动手补全的关键代码片段，配上真实运行输出。不用贴全部代码，但要让别人能看出你做了什么、结果如何。数据准备：加载、划分、标准化三行；sklearn 训练预测：lr.fit(Xtr_s, ytr) 和两组 predict；4a 公式计算：w1_manual、w0_manual 两行；4b 类 fit/predict：intercept_、coef_ 的赋值和 X @ coef_ + intercept_；

⑤结果与分析。用图表呈现结果，每张图配一段中文解释，讨论要落到具体数字。例如训练/测试六项指标表（集合 | MSE | RMSE | R^2）、手动实现与 sklearn 的测试指标对照、两幅图及相应图片解读**（图片中必须包含本人学号，位置不限）**、尺度说明与数值误差及泛化差距讨论；

⑥（可选）问题与学习小结。真实报错或自查（位置、报错信息、原因、修改、再验证结果），课上待补项与课后补做结果；

⑦（可选）AI 协作声明。注明使用的 AI 情况，未使用则明确写明。

五、评分标准

本实验满分 10 分：实验表现 5 分＋实验报告 5 分。实验表现按出勤与参与度给分，实验报告：规范与可复现 1.5 分，代码质量与对照 2 分，分析与图表 1.5 分。